

強化学習における多目的同時最適化のSOTA手法に関する専門的報告書

I. 序論: 多目的強化学習(MORL)のパラダイムとSOTAの評価基盤

多目的強化学習(Multi-Objective Reinforcement Learning: MORL)は、ビデオゲーム、ナビゲーション、ロボティクスといった現実世界の多様なシナリオにおいて、複数の競合する目的を同時に最適化する逐次的意思決定問題に対応するために発展してきた研究領域である¹。標準的な強化学習(RL)が単一のスカラー報酬関数 $R(s, a)$ を最適化するのに対し、MORLでは、エージェントは状態 s と行動 a に基づくベクトル報酬関数 $\mathbf{R}(s, a) = (R_1, R_2, \dots, R_K)$ を受け取るMulti-Objective Markov Decision Process (MOMDP) として定式化される²。

1.1 MORLの形式化: MOMDPsとパレート最適性の概念

報酬がベクトル化されるため、MORLにおいては、単一の「最適な」ポリシーは存在せず、代わりに支配関係に基づいたパレート最適解の集合 Π^* を求めることが目標となる。パレート最適性とは、あるポリシー π の期待リターンベクトル $\mathbf{J}(\pi)$ よりも、少なくとも一つの目的を改善しつつ、他のどの目的も悪化させないような、支配的なポリシーが存在しない状態を指す。この最適解の集合から導かれる目的空間上の境界をパレートのフロンティア(Pareto Front: PF)と呼ぶ³。

従来のMORLアプローチの多くは、線形スカラー化(Linear Scalarisation)などの手法を採用し、選好重み $\mathbf{w}$ を用いてベクトル報酬を単一のスカラー報酬に変換することで、問題を単一目的RLに帰着させていた。例えば、MO Q-Learning関数は、この線形スカラー化を適用する代表的な手法である⁴。しかし、このスカラー化手法は構造的な限界を持つ。特に、報酬空間が非凸な形状を持つ場合、このアプローチではパレートのフロンティア全体ではなく、その凸カバー集合(Convex Cover Set: CCS)内の解しか見つけられないという理論的制約が存在する⁴。

最新鋭(SOTA)の手法の開発は、このCCSの限界を打破し、非凸性を含めたPF全体を効率的かつ網羅的に学習することに焦点を当てている¹。これは、MORLの進化が、単なる既存RLアルゴリズムの適用から、競合する目的を単一のネットワーク構造でいかに効率的に表現しきるかという、モデルの表現能力(Model Capacity)の最大化に移行していることを示している⁶。

1.2 SOTA判定基準: 定量的評価指標の厳密な定義

MORLアルゴリズムの性能を評価するためには、単一の期待リターン値ではなく、解の集合としてのPFの品質を測定するセットベースの指標が必須である⁷。これらの指標は、PFの**収束性(真のPFへの近さ)**と多様性(PFのカバレッジと均一性)**を同時に測定する。

MORLにおいて最も広く受け入れられているSOTA指標は、以下の通りである⁸。

- **Hypervolume (HV):** PFの品質を測る上で最も重要な指標であり、近似PFが報酬空間内で参

照点 (Reference Point) に対して支配する体積を測定する⁷。HV値が高いほど、近似PFが真のPFに近づいており(収束)、かつ広い範囲をカバーしている(多様性)ことを示す¹。HVの計算は高次元目的空間で大きな計算負荷を伴うことがある¹¹。

- **Sparsity / Cardinality:** Sparsityは、PF上の解の分布の均一性を示す指標である。値が低いほど、解が報酬空間全体にわたって密に、かつ均等に分布していることを示す¹。Cardinality (要素数)は、見つけられたパレート解の数を示す指標である⁷。これらの指標は、政策集合の多様性を定量的に評価するために使用される。
- **Inverted Generational Distance (IGD/IGD+):** 真のPFが既知の場合に、近似PFの収束性と多様性を総合的に評価する指標である⁷。従来のIGDはパレート非準拠性(ある支配的な解の集合が、非支配的な解の集合よりも悪い評価を受ける可能性)を持つが、最近提案されたIGD+はこの問題を改善し、HVと類似した特性を持つことが示されている¹¹。

これらのセットベースの指標、特にHVの最大化とSparsityの最小化は、現在のMORLにおけるSOTAアルゴリズムの主要な競争軸となっている。

Table 1: MORL評価指標の分類と特性

分類	指標 (Metric)	測定対象	SOTA MORLにおける役割
収束・カバレッジ	Hypervolume (HV) ⁷	PFが占める報酬空間の体積	総合的なPFの質のSOTA指標。参照点依存性が高い。
多様性	Sparsity / Cardinality ¹	PF上の解の密な分布	PFが選好空間全体を均等にカバーしているかを評価。
収束・多様性	Inverted Generational Distance (IGD/IGD+) ⁷	真のPFから近似PFまでの平均距離	HVの計算負荷が高い場合の代替案。IGD+はパレート準拠性を持つ。
ユーザー選好	Expected Utility Metric (EUM/MUL) ⁷	選好分布に基づく期待効用/最大効用損失	実用的なポリシー選択の指針を提供。

II. 最新鋭の手法1: ハイパーネットワークを用いたパレート集合学習 (PSL-MORL)

PSL-MORL (Pareto Set Learning for MORL) は、多目的問題の解決における表現能力とPFカバレッジにおいて、顕著な優位性を示すSOTAフレームワークである⁶。これは、単一のポリシーや固定された重み付けに依存する従来手法の限界を克服するために提案された、分解ベースの新しい手法である¹。

2.1 PSL-MORLの基本的アプローチとハイパーネットワークの活用

PSL-MORLは、選好重み $\mathbf{w}$ に基づいて多目的問題をスカラー化された部分問題に分解するという、進化型多目的最適化(MOO)から着想を得たアプローチを採用している。

このフレームワークの技術的核は、ハイパーネットワーク(Hypernetwork)の活用にある¹。ハイパーネットワーク H は、選好ベクトル $\mathbf{w}$ を入力として受け取り、その選好に対応するポリシーネットワークのパラメータ $\theta_{\mathbf{w}}$ を出力するように訓練される¹。この機構により、単一のメタネットワーク(ハイパーネットワーク)を学習するだけで、選好 $\mathbf{w}$ の変化に応じて、パーソナライズされた最適ポリシーが効率的に生成される¹。

従来のMORL手法は、全ての選好に対して単一のポリシーネットワークを用いるか、個別のポリシーを学習・保存する必要があった。PSL-MORLは、このアプローチにより、訓練時に存在しなかった新しい選好に対しても、柔軟かつ迅速に最適なポリシーを導出できる、極めて高いパーソナライゼーション能力を持つ。この仕組みは、最適化の対象を「特定のポリシー」から「選好空間全体をカバーする最適ポリシー集合」へと昇華させるメタ最適化の一種として機能する。

2.2 理論的保証と汎用性

PSL-MORLの強みは、その実験的性能だけでなく、理論的な裏付けにもある。

1. モデル容量の優位性: PSL-MORLは、既存手法と比較してモデル容量の優位性が理論的に保証されており、複雑な非凸なPFに対しても最適な政策ネットワークを生成できることが示されている⁶。この理論的な健全性は、アルゴリズムの信頼性を高める上で決定的な要素となる。
2. RLアルゴリズムとの高い互換性: PSL-MORLは、DDQNやPPOなど、任意の既存の単一目的RLアルゴリズムと統合可能な汎用的なフレームワークとして設計されている¹。

2.3 効率性とベンチマーク性能

PSL-MORLは、学習効率の課題に対処するため、選好空間を複数の部分空間に分割する戦略を採用し、アルゴリズムのサンプル効率を向上させている。また、多次元選好補間器

$\mathcal{I}(\omega)$ を利用することで、生成された解を選好ベクトルと整合させる⁶。MORLにおけるサンプル効率の課題は、単一の最適ポリシーではなくポリシー集合全体を学習しなければならない点に起因する¹⁴。PSL-MORLのこの分解と補間戦略は、この課題に対する技術的対応の一つである。

実験結果は、PSL-MORLがMO-MuJoCoなどの連続制御ベンチマークにおいて、既存のSOTA手法を大幅に上回る性能を示したことを立証している。特に、Hypervolume (HV) および Sparsity (SP) の両指標において最高のスコアを達成しており¹、これはPSL-MORLの政策生成器としての能力が、

PFの網羅性と多様性の点で優れていることを示している¹³。

III. 最新鋭の手法2: 効率的なパレートフロンティア発見のための制約付きMORL (C-MORL)

C-MORL (Constrained MORL) は、特に目的の数が多い環境におけるPFの迅速かつ完全な発見を目的とした、制約ベースの二段階ポリシー最適化アルゴリズムである³。C-MORLは、表現能力の最大化を目指すPSL-MORLとは異なり、多目的スケーラビリティと実行効率に焦点を当てたSOTAアプローチである。

3.1 制約最適化の原則と二段階フレームワーク

C-MORLは、古典的な多目的最適化(MOO)における ϵ -制約法にインスパイアされており¹⁶、問題設定を以下のように変換する。すなわち、一つの目的 R_i を最大化しつつ、他の $K-1$ 個の目的 R_j ($j \neq i$)の値を特定の閾値(制約) ϵ_j 以上に保つという定式化を用いる³。

この制約付き最適化アプローチを効率的に実行するため、C-MORLは二段階構造を採用する³。

1. **パレート初期化段階 (Pareto Initialization):** 初期探索により、PFの角点や代表的な解の初期集合を見つける。
2. **パレート拡張段階 (Pareto Extension):** 初期解を基に制約付き最適化を適用し、PFの未発見の空隙を埋める。特に、**Crowd Distance**に基づくポリシー選択スキームにより、PF上の解が疎な領域を優先的に探索する³。これにより、PFの均一なカバレッジが促進される。

3.2 内点法に基づく制約処理と理論的効率性

C-MORLの主要な技術的革新は、制約付き最適化問題の効率的な経験的解決方法にある。C-MORLは、 ϵ -制約法に付随する追加の計算負荷を回避するため、**内点法 (Interior-Point-Based Approach)** に基づく緩和された定式化を採用する¹⁵。

この内点法アプローチにより、制約付き最適化を効率的に解くことが可能となり、調整可能な対数バリアパラメータ t を用いて、最適解からの最大ギャップが $\frac{n-1}{t}$ で境界付けられることが理論的に示されている¹⁵。これは、C-MORLが厳密な実行可能性を保証しつつ、効率的にパレート最適ポリシーを導出できることを意味する。

3.3 スケーラビリティと計算複雑性の優位性

C-MORLの最も決定的な優位性は、その高いスケーラビリティと低計算複雑性にある。

C-MORLは、目的数 n が増加するにつれて発生するPF探索空間の指数関数的な増大(多目的の呪い)への強力な対策を提供する。実験結果は、C-MORLが、最大9つの目的を持つ環境を含む多様なベンチマークにおいて、一貫して優れた性能を達成していることを示している³。

さらに、C-MORLのアルゴリズムは、理論的に目的数 n に対して線形時間計算量 $O(n)$ を持つことが分析されている¹⁵。これは、多目的決定問題 (Many-Objective Decision Making) において、目的数が非常に多い場合に、他のより複雑なネットワーク構造を持つSOTA手法に対する決定的な優位性をもたらす。ポリシーの並列学習 (Pareto InitializationおよびExtensionの各段階)も、総実行時間をさらに短縮することに寄与する¹⁵。

C-MORLは理論的な効率性を強く追求しているが、実環境での適用に際しては、注意が必要な側面がある。C-MORLが主張する効率性 (線形時間計算量 $O(n)$) は、主に各学習ステップの計算時間に適用されるものであり、環境との相互作用回数 (サンプル効率) の改善に直接結びつかない可能性がある。実際、複雑なMuJoCoタスクでの評価では、依然として数千万ステップの環境相互作用が必要であるという懸念が指摘されている¹⁸。MORLでは政策集合を学習するため、単一目的RLと比較してサンプル効率の問題が深刻化するため¹⁴、実運用においては、アルゴリズムの実行速度とデータ収集コストの両方を総合的に評価する必要がある。

IV. 他の重要な深層MORLアプローチと発展: 基盤技術の進化

MORLのSOTA競争は、PSL-MORLやC-MORLといった革新的なフレームワークに集中しているが、既存の基盤技術 (DQNやPPO) を多目的に拡張する研究も、特定の問題設定や効率性の要求において重要な進展を見せている。

4.1 選好駆動型MORL (PD-MORL) とパラメトリックポリシー

PD-MORL (Preference-Driven MORL) は、PSL-MORLと共通の目標を持ちながら、異なるアプローチを採用する。PD-MORLは、選好ベクトル $\mathbf{w}$ を入力として受け取る単一の普遍的な政策ネットワークを訓練し、選好空間全体をカバーすることを目指す¹⁹。

PD-MORLは、ポリシーを個別に保存する必要がなく、既存手法と比較して訓練可能なパラメータ数を桁違いに削減しながら、連続制御タスクで高いHypervolumeを達成できる¹⁹。これは、リソースが制約される環境や、ポリシーのストレージ効率が課題となる場合に、極めて実用的なSOTAとして機能する。しかし、表現能力の点では、ポリシーのパラメータ自体を生成するPSL-MORLに譲る可能性があり、最大精度よりもパラメータ効率と一般化能力を優先する設計思想を持つ。

4.2 MO-DQN系列の安定性と探索能力の向上

深層Qネットワーク (DQN) をベースとしたMORL手法は、その不安定性と探索不足の問題に対処するために進化している。

- **EDNs (Envelope with Dueling structure, Noisynet, and Soft update):** 収束の不安定性と探索不足の解決を目指す手法である²⁰。このアルゴリズムは、価値関数を近似するためにDueling Network構造を採用することで収束を高速化し、さらに**Noisynet**を用いてネットワークパラメータに探索ノイズを追加することで、エージェントの探索能力を効率的に向上させる²⁰。
- **LSMO-DQN (Linear Scalarized Multi-objective Deep Q-Network):** 線形スカラー化を報

報酬処理に組み込み、即時フィードバックを提供することで学習プロセスを加速し、アルゴリズムの安定性を高める²¹。LSMO-DQNは、実装が比較的容易であり、動的環境での迅速な調整に利点を持つが、線形スカラー化の限界により、非凸PFの解を見つける能力はCCSに限定される²¹。

4.3 PPO/Actor-Criticベースの拡張

Actor-Critic法をベースとする手法、特にPPO (Proximal Policy Optimization) は、複雑な多段階意思決定タスクにおいて安定した学習特性を持つため、MORLでも拡張が試みられている。

- **3PO (Three-Policy Optimization):** 複数のPPOユニットを使用し、各目的が独立したPPOユニットに対応する構造を持つ²²。このフレームワークは、PPOの安定した学習特性を多目的に応用する一例である。
- **多目的GRPO:** PPOの計算複雑性と計算負荷を軽減するために開発されたGRPO (Group-sampling-based PPO) のような手法は、多目的報酬計算の文脈でもその効率性が検討されている²³。PPOベースの手法は、効率性と安定性を両立させるための技術的基盤として利用され続けている。

これらの基盤技術の拡張を通じて、MORLにおける探索戦略は、単なる状態空間の探索ではなく、選好空間の探索の側面も持つことが明らかになっている²⁴。EDNsがNoisyNetでパラメータ空間を探索するように、SOTA手法は、状態 s と選好 $\mathbf{w}$ の組み合わせ $(s, \mathbf{w})$ に対する効果的な探索戦略を組み込む必要がある。選好そのものを状態の一部として扱う「Surrogate State Space」の概念も、動的な選好や不確実な選好に対応するための将来的な方向性として浮上している²⁴。

V. 定量的性能評価とベンチマーク分析

SOTAの主張を確立するためには、標準化されたベンチマーク環境と、HypervolumeやSparsityのような厳密なセットベースの指標による定量的検証が不可欠である⁷。

5.1 標準ベンチマーク環境

MORL研究の標準化は、MO-Gymnasiumライブラリによって推進されている。これはOpenAI Gym APIを拡張し、多目的マルコフ決定過程 (MOMDP) を含む多様な多目的環境と、標準化された評価APIを提供することで、アルゴリズムの再現性と性能比較を容易にしている²。

主な評価環境としては、複雑な連続行動空間におけるポリシーの性能を測る**MO-MuJoCo**ベンチマーク (例: MO-Walker2d, MO-HalfCheetah) や、ディスクリート環境における探索とポリシーの収束能力を評価する****FTN (Fruit Tree Navigation)****などが利用されている¹。

5.2 PSL-MORLのベンチマークにおける優位性

PSL-MORLは、MO-MuJoCoなどの広範な連続制御ベンチマークにおいて、Hypervolume (HV) および Sparsity (SP) の両方で、既存の有力なベースライン (PD-MORLやEnvelopeなど) に対して一

貫した優位性を示している¹。

MO-Walker2d-v2におけるHV $5.36 (\times 10^6)$ や、MO-HalfCheetah-v2におけるHV $5.92 (\times 10^6)$ といった数値は、PSL-MORLが最も広範な範囲をカバーし、かつ最も質の高いパレートフロンティアを近似していることを示す¹。

特に、Sparsityが非常に低い値(例: $0.01 (\times 10^4)$)であるという事実は、PSL-MORLの技術的な優位性を強力に裏付ける。これは、単に質の高い解の集合を見つけただけでなく、ハイパーネットワークが選好入力からポリシーパラメータへの写像を非常に滑らかに学習し、結果としてPF上に解を意図的に、かつ極めて均等に配置する能力に優れていることを示唆している¹。したがって、ユーザーが特定のトレードオフの要求(選好)を提示した場合、PSL-MORLはベースラインよりもその要求に「正確に合致した」カスタマイズされたポリシーを提供できる可能性が高い。

5.3 C-MORLの多目的環境における位置づけ

C-MORLは、特に目的の数が多い($n \geq 5$)環境での性能維持と効率性を最大の強みとして主張している³。目的数が大きくなると、PSL-MORLのハイパーネットワークの訓練やPD-MORLの普遍ネットワークの一般化が難しくなることが予想されるため、C-MORLの線形計算複雑性 $O(n)$ は、高次元目的空間におけるSOTA候補としての地位を確立する。

しかし、既存のベンチマーク(MO-MuJoCo, FTN)は主に2~3目的であり、これらの環境ではPSL-MORLが明確な優位性を示す¹。SOTAの全体像を捉えるためには、低次元における表現学習の優位性(PSL-MORL)と、高次元における計算論的効率性(C-MORL)という、異なる技術的課題に対する解決策を相補的に評価する必要がある。

Table 2に、主要SOTA MORL手法の定量的性能比較(MO-MuJoCoおよびFTN)の概略を示す。

Table 2: 主要SOTA MORL手法の定量的性能比較(一部抜粋)

ベンチマーク環境	指標	PSL-MORL (Ours)	PD-MORL	Envelope
MO-Walker2d-v2	HV ($\times 10^6$)	5.36 ¹	-	-
MO-Walker2d-v2	Sparsity ($\times 10^4$)	0.01 ¹	-	-
MO-HalfCheetah-v2	HV ($\times 10^6$)	5.92 ¹	(5.62, PSL-MORL-ad)	-

			d)	
FTN (Depth 7)	Hypervolume	11786.10 ¹	11419.58	6395.27

※C-MORLは、その優位性が目的数 $n \geq 5$ の環境にあるため、上記の低次元ベンチマークでの直接的なトップスコアは報告されていない³。

VI. 結論、今後の課題、および技術的推奨事項

6.1 SOTA手法の総合評価

強化学習における多目的同時最適化の分野は、従来の線形スカラー化の限界を打破し、パレートフロンティアの全体像を網羅的かつ高精度に近似するフェーズに移行している。現在のSOTAは、以下の二つの主要な手法によって確立されている。

1. 総合的**SOTA (PF品質、多様性重視): PSL-MORL**。ハイパーネットワークを用いて選好ベクトルからカスタマイズされたポリシーパラメータを生成するこのアプローチは、理論的なモデル容量の優位性を背景に、MO-MuJoCoなどのベンチマークにおいて、HypervolumeおよびSparsityの両方で最高の定量的性能を達成している¹。これは、訓練後にユーザーが任意の選好 $\mathbf{w}$ を指定した際、即座に最適な個別化ポリシーを提供できるという実用的な強みを持つ。
2. スケーラビリティ**SOTA (多目的、実行効率重視): C-MORL**。内点法を用いた制約ベースの最適化をRLに統合することで、目的数 n に対して線形計算複雑性 $O(n)$ を実現する¹⁵。これにより、特に目的数が5つ以上といった多目的決定問題において、効率性と安定性の点で決定的な優位性を持つ。

6.2 MORLの未解決の課題と今後の研究方向

MORLの進展にもかかわらず、実環境への適用を阻むいくつかの重要な課題が残されている。

- サンプル効率の改善: MORLアルゴリズムは、単一の最適解ではなく、最適な政策の集合(パレート集合)を学習しなければならないため、環境との相互作用コスト(サンプル効率)が単一目的RLに比べて著しく高くなる¹⁴。今後の研究は、PSL-MORLにおける選好補間器⁶やPD-MORLの並列化戦略¹⁹のさらなる強化に加え、データ収集コストが高い実環境への適用のために、オフラインMORLや高効率なモデルベースMORLへの移行が求められる。
- 動的な選好への対応: 既存のSOTA手法の多くは、選好ベクトル $\mathbf{w}$ が静的であることを前提としている。しかし、現実世界、特に複雑な制御問題においては、選好やトレードオフは時間と共に、または状態に依存して変化する²⁴。動的な選好ダイナミクスを内包し、状態依存的な選好(State-Dependent Preferences)の下で意思決定を行うことができるMORLフレームワークの構築が、次世代の技術的課題となる。
- 実務的な意思決定支援の強化: パレートフロンティアを発見した後、エージェントがユーザーの真の効用関数に最も合致するポリシーを選択するためのメカニズムが重要となる。Mismatch metric²⁵やExpected Utility Metric (EUM)⁷のような、ユーザーの選好と政策の整合性を定量

化し、最適なポリシーを推奨する仕組みの統合が、MORLの実用化を促進する鍵となる。

6.3 専門家としての技術的推奨事項

MORL手法の選択は、プロジェクトの目的、特に目的の数と計算資源の制約に依存して決定されるべきである。

Table 3: SOTA MORL手法の適用シナリオに基づく推奨

目的	推奨SOTA手法	理由
PF品質の最大化(HV, Sparsity)	PSL-MORL ¹	ハイパーネットワークによる最高の表現能力と、任意の選好に対するポリシー個別化能力。
多目的スケーラビリティ(目的数 $n \geq 5$)	C-MORL ³	目的数に対する線形時間計算量 $O(n)$ による実行効率と安定性。
パラメータ効率とメモリ制約	PD-MORL ¹⁹	単一の普遍ネットワークによる効率的なポリシー表現とパラメータ削減。
既存RLシステムへの統合	PSL-MORL ⁶	任意の単一目的RLアルゴリズムとの高い互換性を持つ汎用フレームワーク。

引用文献

1. Pareto Set Learning for Multi-Objective Reinforcement Learning, 12月 3, 2025にアクセス、<https://ojs.aaai.org/index.php/AAAI/article/view/34068/36223>
2. MO-Gym: A Library of Multi-Objective Reinforcement Learning Environments - UMass CICS, 12月 3, 2025にアクセス、https://people.cs.umass.edu/~bsilva/papers/MO-Gym_BNAIC_2022.pdf
3. Efficient Discovery of Pareto Front for Multi-Objective Reinforcement Learning - arXiv, 12月 3, 2025にアクセス、<https://arxiv.org/html/2410.02236v2>
4. Limitations of Scalarisation in MORL: A Comparative Study in Discrete Environments - arXiv, 12月 3, 2025にアクセス、<https://arxiv.org/html/2511.16476v1>
5. A Generalized Algorithm for Multi-Objective Reinforcement Learning and Policy Adaptation - NIPS papers, 12月 3, 2025にアクセス、

- <http://papers.neurips.cc/paper/9605-a-generalized-algorithm-for-multi-objective-reinforcement-learning-and-policy-adaptation.pdf>
6. Pareto Set Learning for Multi-Objective Reinforcement Learning - arXiv, 12月 3, 2025にアクセス、<https://arxiv.org/html/2501.06773v1>
 7. Performance assessments - MORL-Baselines 1.1.0 documentation - Lucas N. Alegre, 12月 3, 2025にアクセス、
<https://lucasalegre.github.io/morl-baselines/algos/performances/>
 8. Exploring SOTA: A Guide to Cutting-Edge AI Models | DigitalOcean, 12月 3, 2025にアクセス、
<https://www.digitalocean.com/community/tutorials/exploring-sota-guide-to-cutting-edge-ai-models>
 9. What Are the SOTA AI Models? | Machine Learning Glossary - Mad Devs, 12月 3, 2025にアクセス、<https://maddevs.io/glossary/state-of-the-art-models/>
 10. Performance indicators - MORL-Baselines 1.1.0 documentation, 12月 3, 2025にアクセス、
https://lucasalegre.github.io/morl-baselines/features/performance_indicators/
 11. Comparison of Hypervolume, IGD and IGD+ from the Viewpoint of Optimal Distributions of Solutions | Semantic Scholar, 12月 3, 2025にアクセス、
<https://www.semanticscholar.org/paper/Comparison-of-Hypervolume%2C-IGD-and-IGD%2B-from-the-of-Ishibuchi-Imada/c9800315784f3a1423ace210bee57c7a0eaa1d3f>
 12. [2501.06773] Pareto Set Learning for Multi-Objective Reinforcement Learning - arXiv, 12月 3, 2025にアクセス、<https://arxiv.org/abs/2501.06773>
 13. Pareto Set Learning for Multi-Objective Reinforcement Learning - arXiv, 12月 3, 2025にアクセス、<https://arxiv.org/html/2501.06773v2>
 14. Sample-Efficient Multi-Objective Learning via Generalized Policy Improvement Prioritization - UMass CICS, 12月 3, 2025にアクセス、
https://people.cs.umass.edu/~bsilva/papers/MORL_GPI_aamas_2023.pdf
 15. C-MORL: Multi-Objective Reinforcement Learning through Efficient Discovery of Pareto Front - arXiv, 12月 3, 2025にアクセス、<https://arxiv.org/html/2410.02236v1>
 16. C-MORL: Multi-Objective Reinforcement Learning through Efficient Discovery of Pareto Front - ResearchGate, 12月 3, 2025にアクセス、
https://www.researchgate.net/publication/384630691_C-MORL_Multi-Objective_Reinforcement_Learning_through_Efficient_Discovery_of_Pareto_Front
 17. Pareto Optimization or Cascaded Weighted Sum: A Comparison of Concepts - MDPI, 12月 3, 2025にアクセス、<https://www.mdpi.com/1999-4893/7/1/166>
 18. Multi-Policy Pareto Front Tracking Based Multi-Objective Reinforcement Learning | OpenReview, 12月 3, 2025にアクセス、
<https://openreview.net/forum?id=K3E05Agd6W>
 19. PD-MORL: Preference-Driven Multi-Objective Reinforcement Learning Algorithm, 12月 3, 2025にアクセス、<https://openreview.net/forum?id=zS9sRyaPFIJ>
 20. An Improved Multi-Objective Deep Reinforcement Learning Algorithm Based on Envelope Update - MDPI, 12月 3, 2025にアクセス、
<https://www.mdpi.com/2079-9292/11/16/2479>
 21. Addressing Immediate and Delayed Rewards in Multi-Objective Q-Learning - IEEE

- Xplore, 12月 3, 2025にアクセス、
<https://ieeexplore.ieee.org/iel8/6287639/10380310/10685374.pdf>
22. POI Recommendation via Multi-Objective Adversarial Imitation Learning, 12月 3, 2025にアクセス、<https://ojs.aaai.org/index.php/AAAI/article/view/33382/35537>
 23. TaoSearchEmb: A Multi-Objective Reinforcement Learning Framework for Dense Retrieval in Taobao Search - arXiv, 12月 3, 2025にアクセス、
<https://arxiv.org/html/2511.13885v1>
 24. Robust Multi-Objective Reinforcement Learning with Dynamic Preferences, 12月 3, 2025にアクセス、
<https://proceedings.mlr.press/v189/buet-golfouse23a/buet-golfouse23a.pdf>
 25. Learning and Selection of Pareto Optimal Policies Matching User Preferences - IEEE Xplore, 12月 3, 2025にアクセス、
<https://ieeexplore.ieee.org/iel8/6287639/10380310/10599158.pdf>